

Guide Juridique Tunisien

Cahier des charges

Projet

Agent IA Juridique Tunisien

Domaine

Droit tunisien, aide aux citoyens

Technologies

Python · LangGraph · Groq · ChromaDB · Gradio ·

LLM

httpx Llama 3.3 70B via Groq API

Réalisé par

Yasmine Laouini

Yasmine Hamza

Arij Dridi

1. Introduction et Contexte

Le projet **Guide Juridique Tunisien** est un agent IA conversationnel conçu pour démocratiser l'accès au droit tunisien. La majorité des citoyens tunisiens n'ont pas accès à un avocat pour des questions quotidiennes telles que le licenciement, les droits du travail, ou les procédures administratives. Les lois existent en arabe et en français, dispersées dans des documents officiels difficiles à consulter, et le jargon juridique est inaccessible au grand public.

Problématique : Aucun accès simple, gratuit et bilingue aux informations juridiques tunisiennes. Les outils existants sont soit en anglais, soit nécessitent un abonnement payant, soit n'ont pas accès aux sources officielles tunisiennes.

Solution : Un agent IA capable de répondre en langage naturel aux questions juridiques des citoyens, en citant les articles de loi pertinents, en calculant des délais légaux, et en analysant des documents juridiques fournis par l'utilisateur — en français ET en arabe.

2. Solutions Envisagées

Trois approches ont été évaluées avant de choisir l'architecture finale :

2.1 RAG Classique (Retrieval-Augmented Generation)

Le RAG classique consiste à vectoriser les documents juridiques, puis à récupérer les fragments les plus pertinents pour chaque question avant de les passer au LLM. Cette approche est simple et rapide, mais souffre de plusieurs limitations critiques pour notre cas d'usage :

les lois tunisiennes évoluent régulièrement (nouveaux décrets, JORT), et le RAG classique nécessite une ré-ingestion complète pour chaque mise à jour. De plus, il ne peut effectuer qu'une seule passe de récupération — incapable de croiser plusieurs sources ou d'enchaîner des raisonnements.

2.2 Fine-tuning d'un LLM

Le fine-tuning consiste à ré-entraîner un modèle de langage sur le corpus juridique tunisien pour qu'il intègre les connaissances directement dans ses poids. Cette approche offre des réponses très fluides mais présente des obstacles majeurs : coût prohibitif (plusieurs milliers de dollars de GPU), impossibilité de vérifier les sources citées, et nécessité de ré-entraîner entièrement à chaque mise à jour législative.

2.3 Agent ReAct — Solution retenue

Le paradigme **ReAct** (Reasoning + Acting) combine les avantages des deux approches précédentes tout en éliminant leurs inconvénients. L'agent raisonne (Thought), agit en appelant un outil (Action), lit le résultat (Observation), et recommence jusqu'à produire une réponse complète et sourcée. Cette architecture permet une mise à jour en temps réel via le scraping web, une citation systématique des sources, et un raisonnement multi-étapes.

Critère	RAG Classique	Fine-tuning LLM	Agent ReAct
Mise à jour des lois	Ré-ingestion	Ré-entraînement	Scraping auto
Raisonnement multi-étapes	Une passe	Limité	Boucle ReAct
Source vérifiable	Parfois	Non	Article + URL
Support bilingue fr/ar	Selon modèle	Selon données	Embeddings 50+ langues
Analyse de documents	Non	Non	Outil dédié
Coût infrastructure	Faible	Très élevé	Faible (API)

3. Avantages Concurrentiels

• Données officielles uniquement

9anoun.tn héberge les codes juridiques tunisiens officiels ET toutes les éditions du JORT en HTML propre. Chaque réponse de l'agent cite l'article exact avec son URL 9anoun.tn , vérifiable directement par l'utilisateur. Contrairement aux assistants généralistes qui peuvent halluciner des lois inexistantes.

• Bilingue natif français / arabe

Le modèle d'embeddings paraphrase-multilingual-MiniLM-L12-v2 supporte 50+ langues dont le français et l'arabe. L'agent peut répondre à une question en arabe, rechercher dans une base bilingue, et retourner une réponse traduite. C'est le seul assistant juridique tunisien vraiment bilingue.

• Toujours à jour sans ré-ingestion

Le signal CONFIANCE_FAIBLE déclenche automatiquement le scraping de 9anoun.tn/kb/jorts pour récupérer les derniers décrets. Les nouvelles lois publiées au JORT sont accessibles sans aucune intervention humaine , contrairement au RAG classique qui nécessite une ré-ingestion manuelle.

• Zéro infrastructure GPU

L'architecture ChromaDB local + Groq API ne nécessite aucun serveur GPU. Le projet est déployable gratuitement sur HuggingFace Spaces (gradio deploy) avec une seule commande — accessible à tout citoyen depuis un navigateur.

• Analyse de documents personnels

L'utilisateur peut uploader son propre contrat de travail, mise en demeure ou jugement. L'agent identifie les clauses risquées (non-concurrence, clause pénale, période d'essai), les parties, et vérifie leur légalité au regard du droit tunisien en vigueur.

4. Architecture Générale du Système

4.1 Vue d'ensemble — Cycle ReAct

L'agent est construit avec LangGraph `create_react_agent`. À chaque question, le LLM génère un raisonnement interne (Thought), choisit l'outil le plus adapté (Action), lit le résultat retourné (Observation), et recommence jusqu'à 6 itérations maximum pour formuler une réponse complète et sourcée.

Couche	Composant	Rôle
Interface	Gradio 4.x	Chat web, upload PDF, exemples pré-remplis, mode sombre
Agent	LangGraph <code>create_react_agent</code>	Boucle ReAct, gestion des outils, mémoire glissante
LLM	Groq — Llama 3.3 70B Versatile	Raisonnement principal, génération de texte, citations
Outils	4 fonctions @tool Python	Recherche, web search, traduction, analyse document
Mémoire	Sliding window 2 échanges	Historique sans dépasser le TPM Groq (6k tokens/min)
Base vectorielle	ChromaDB persistant	Stockage des embeddings des 7 PDFs juridiques officiels
Embeddings	paraphrase-multilingual-MiniLM	Vectorisation français + arabe (50+ langues, dim=384)
Web scraper	htpx HTTP/2 + BeautifulSoup	9anoun.tn/kb/codes + 9anoun.tn/kb/jorts — cache 1h
Corpus	7 PDFs officiels tunisiens	Code Travail, Code Pénal, JORT, Constitution 2022...

4.2 Les 4 outils de l'agent

<code>search_legal_docs(query)</code>	Quand : Toujours en premier
Recherche sémantique dans ChromaDB. Retourne les articles pertinents avec source et score de confiance. Si score < 40% → retourne le signal <code>CONFIANCE_FAIBLE</code> qui déclenche <code>web_search_jort</code> .	
<code>web_search_jort(keywords)</code>	Quand : Si <code>CONFIANCE_FAIBLE</code>
Scrape <code>9anoun.tn/kb/codes/{slug}</code> pour les codes et <code>9anoun.tn/kb/jorts</code> pour les éditions JORT. Utilise <code>htpx HTTP/2</code> avec cache mémoire 1 heure. Remplace <code>iort.gov.tn</code> (app WinDev, non-scrappable).	
<code>translate_legal_text(dir texte)</code>	Quand : Question en arabe

Traduction ar↔fr via Helsinki-NLP (opus-mt-ar-fr / opus-mt-fr-ar). Pipeline chargé une seule fois en mémoire cache. Format d'entrée : texte français.

analyze_document(text_content)

Quand : Document uploadé

Pré-analyse légère du document : détection parties, clauses/articles, mots-clés à risque (non-concurrence, clause pénale, nullité...). Retourne une structure annotée pour le LLM.

5. Implémentation Technique

5.1 Ingestion des documents (ingest.py)

Le pipeline d'ingestion s'exécute une seule fois avant le lancement de l'agent. Il charge les PDFs officiels tunisiens avec PyMuPDF (fitz), les découpe en fragments de 512 caractères avec un chevauchement de 100 caractères, les vectorise avec paraphrase-multilingual-MiniLM-L12-v2, et les stocke dans ChromaDB avec les métadonnées (source, page, référence d'article).

Un bug important a été corrigé dans les séparateurs de découpage : le séparateur arabe original

5.2 Scraper web robuste (scraper.py)

Le scraper utilise httpx HTTP/2 avec un cache mémoire TTL d'une heure. Après inspection directe des deux sites cibles, il a été établi que :

- **ior.t.gov.tn** est une application WinDev des années 2000 avec navigation en javascript:{} et tokens de session, impossible à scraper automatiquement. Cette URL a été abandonnée.
- **9anoun.tn** sert du HTML statique sans JavaScript requis et héberge à la fois tous les codes juridiques tunisiens ET toutes les éditions du JORT en HTML propre. Une seule source remplace les deux sources initiales.

5.3 Gestion de la mémoire conversationnelle

Le MemorySaver de LangGraph accumule l'historique de conversation sans limite, ce qui cause rapidement un dépassement de la limite TPM (tokens par minute) du tier gratuit Groq. La solution retenue est une **fenêtre glissante manuelle** : seuls les 2 derniers échanges (4 messages) sont inclus dans chaque requête. Cette approche maintient le contexte des questions de suivi sans dépasser les limites.

6. Résultats des Tests

Le fichier `test_agent.py` couvre 6 scénarios représentatifs des cas d'usage réels. Chaque test utilise un `thread_id` unique pour éviter toute contamination de mémoire, sauf le Test 6 qui réutilise délibérément le thread du Test 1 pour vérifier la mémoire.

Test	Scénario	Outils attendus	Résultat
1	Licenciement sans préavis	search_legal_docs	■ Article 14 Code du Travail cité
2	Décret 2024 (CONFIANCE_FAIBLE)	search + web_search_jort	■ Scraping 9anoun JORT déclenché
3	Baisse de salaire	search_legal_docs	■ Réponse sourcée en < 5s
4	Question en arabe	search + translate	■ Réponse bilingue ar/fr
5	Analyse contrat de travail	analyze_document + search	■ Clauses identifiées
6	Suivi mémoire (réf. Test 1)	search_legal_docs	■ Contexte licenciement maintenu

Note sur le tier gratuit Groq : Les tests sont exécutés avec une pause de 25 secondes entre chaque appel pour respecter la limite de 6000 tokens/minute du tier gratuit. Cette contrainte n'affecte pas l'utilisation normale via Gradio (une question à la fois).

8. Interface Utilisateur (Gradio)

L'interface est construite avec Gradio Blocks pour un maximum de flexibilité. Elle inclut tous les éléments requis ainsi que des fonctionnalités supplémentaires :

Fonctionnalité		Statut
Chat avec historique		■
Zone de saisie	Textbox avec soumission par touche Entrée ou bouton Envoyer	■
Titre et description	En-tête Markdown expliquant le projet et l'avertissement légal	■
Upload PDF	Permet d'analyser un document juridique personnel (2000 chars)	■
Exemples pré-remplis	5 questions exemples pour faciliter la prise en main	■
Mode sombre / clair	Disponible nativement dans Gradio	■
Isolation mémoire	UUID unique par session via <code>demo.load()</code> event	■
Nouvelle conversation	Bouton remet à zéro le chat et génère un nouveau <code>thread_id</code>	

10. Conclusion

Le projet Guide Juridique Tunisien démontre qu'il est possible de construire un assistant juridique IA fiable, bilingue et sourcé pour les citoyens tunisiens, avec un stack technique léger et un coût d'infrastructure quasi nul