

8.2/
10

Guide Juridique Tunisien

Agent IA — Documentation de Projet

Production-ready RAG agent avec données juridiques réelles, support multilingue fr/ar et interface Gradio.

6

Fichiers

4

Outils agent

3

Sources données

12+

Bugs corrigés

Architecture générale

Couche	Composant	Rôle
Interface	Gradio	Chat web, upload PDF, exemples
Agent	LangGraph create_react_agent	Boucle ReAct, gestion outils
LLM	Groq — Llama 3.3 70B	Raisonnement, génération
Outils	4 fonctions Python @tool	Recherche, calcul, analyse, traduction
Mémoire	Sliding window (2 échanges)	Historique sans dépasser le TPM
Base vectorielle	ChromaDB persistant	Embeddings des lois tunisiennes
Embeddings	paraphrase-multilingual-MiniLM	Vectorisation fr/ar
Web scraper	httpx + BeautifulSoup	9anoun.tn codes + JORT
Corpus	7 PDFs officiels tunisiens	Code Travail, Code Pénal, JORT...

Les 4 outils de l'agent

search_legal_docs(query)

Quand : toujours en premier

Recherche sémantique dans ChromaDB. Retourne les articles pertinents avec source et score de confiance. Si score < 40% → retourne CONFIANCE_FAIBLE.

web_search_jort(keywords)

Quand : si CONFIANCE_FAIBLE

Scrape 9anoun.tn/kb/codes/{slug} pour les codes juridiques et 9anoun.tn/kb/jorts pour les éditions JORT. httpx HTTP/2, cache 1h. Remplace iort.gov.tn (incompatible).

translate_legal_text(direction|texte)

Quand : question en arabe

Traduit ar↔fr via Helsinki-NLP. Pipeline chargé une seule fois en mémoire. Format : 'fr|■■■■' ou 'ar|texte français'.

analyze_document(text_content)

Quand : document uploadé

Pré-analyse légère du document : détection parties, clauses, mots-clés à risque (non-concurrence, clause pénale...). Retourne structure pour le LLM.

Bugs corrigés

Corrigé	Embedding mismatch (tools.py) tools.py utilisait SentenceTransformer brut, ingest.py utilisait le wrapper ChromaDB → normalisation différente → scores de similarité incorrects.
Corrigé	XML tool call bug (Groq + LangGraph) bind_tools() appelé séparément causait un double enregistrement des outils → Groq utilisait le format XML au lieu de l'API → Error 400.
Corrigé	Thread ID Gradio (lambda bug) gr.State(value=lambda: uuid4()) stockait l'objet lambda — tous les utilisateurs partageaient le même thread de mémoire.
Corrigé	iort.gov.tn remplacé iort.gov.tn est une app WinDev avec navigation javascript:{} et tokens de session. Impossible à scraper. Remplacé par 9anoun.tn/kb/jorts.
Corrigé	Séparateur arabe (ingest.py) '\n■■■■■■' utilisait les Arabic Presentation Forms (U+FE80) au lieu de l'Unicode standard → le splitter ne matchait jamais les articles.
Corrigé	Formule de confiance $(1 - \text{dist}/2) \times 100$ était faux pour des vecteurs cosinus normalisés. Corrigé : $(1 - \text{dist}) \times 100$.
Corrigé	parallel_tool_calls llama-3.3-70b bascule en XML quand parallel_tool_calls est activé. Désactivé via model_kwargs={'parallel_tool_calls': False}.
Corrigé	Mémoire glissante manuelle MemorySaver accumulait toute l'historique → dépassement TPM. Remplacé par une fenêtre glissante de 2 échanges gérée manuellement.

Limitations actuelles

Limite	Groq free tier 100k tokens/jour, 6k/min. Cause des erreurs 413/429 sur les analyses de PDF et le test mémoire. Solution : Dev tier (\$5/mois).
--------	--

Limite	PDF tronqué à 2000 chars Réduit pour éviter les erreurs TPM. À remonter à 6000–8000 chars après upgrade Groq.
Limite	Modèle traduction Helsinki-NLP (~300 Mo) se télécharge à la première utilisation. Aucun impact en production après ce premier chargement.

Prochaines étapes

Suite	Upgrade Groq Dev tier Débloquer l'analyse PDF complète, le test mémoire stable et un usage production fiable. \$5/mois sur console.groq.com/settings/billing .
Suite	Enrichir ChromaDB Ajouter Code Civil, Code de Commerce, JORT 2024–2025 pour réduire les CONFIANCE_FAIBLE et améliorer la qualité des réponses sans accès web.
Suite	Déployer sur HuggingFace gradio deploy en une commande. Hébergement gratuit, URL publique partageable avec les citoyens tunisiens.

Stack technique

Python 3.13	LangChain	LangGraph 1.2	Groq — Llama 3.3 70B	ChromaDB 0.5+
sentence-transformers	httpx HTTP/2	BeautifulSoup4	Gradio 4.x	PyMuPDF (fitz)
9anoun.tn	JORT via 9anoun	Helsinki-NLP	python-dotenv	reportlab